

5

RLHF

OBJETIVO DE RLHF

- ▶ El objetivo de **RLHF** es que un LLM aprenda a generar respuestas **que un humano preferiría**:
 - ✓ más útiles
 - ✓ más coherentes
 - ✓ menos dañinas



PROBLEMAS DE LOS LLM

- ▶ Los modelos que solo predecían la siguiente palabra a menudo:
 - ✓ Se desviaban.
 - ✓ Inventaban cosas.
 - ✓ Generaban respuestas problemáticas.

PROBLEMAS DE LOS LLM

- ▶ Para resolver estos problemas se buscó **alinearlos**, esto es, **que hagan lo que el usuario busca**, es decir el objetivo era que:
 - ✓ Fueran útiles.
 - ✓ Ayudaran a resolver tareas.
 - ✓ Fueran honestos (que no fabriquen información).
 - ✓ Fueran inofensivos (que no causaran daño).

INTRODUCCIÓN

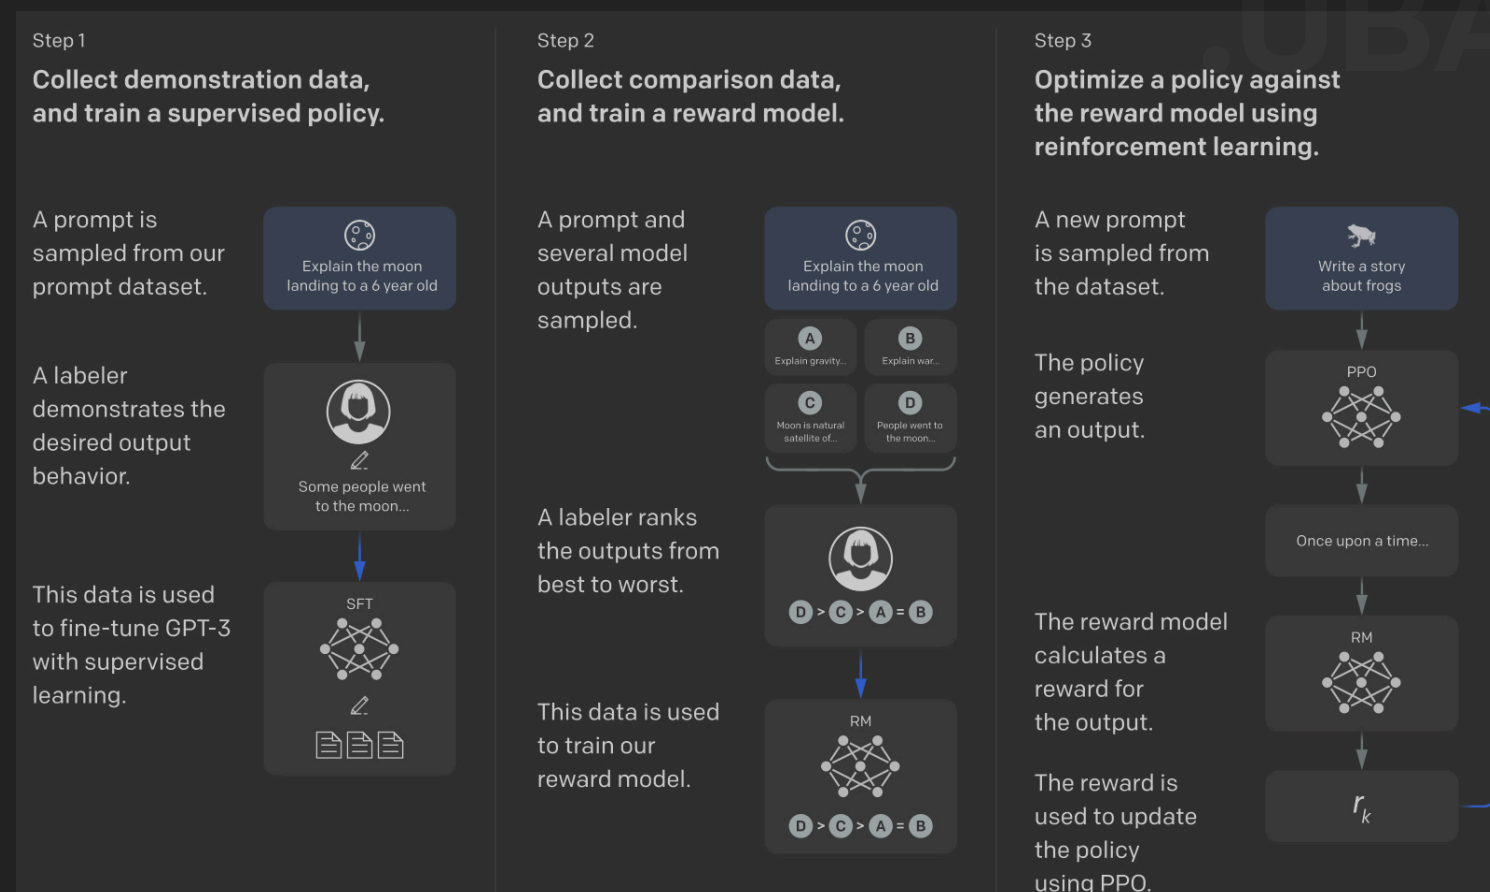
- ▶ **RLHF** (Reinforcement Learning from Human Feedback) es un método para afinar **LLMs** después de que han sido entrenados.
- ▶ El artículo que lo describe se titula “Entrenamiento de modelos de lenguaje para seguir instrucciones con retroalimentación humana” (Ouyang et al., 2022).



CICLO DE VIDA DE RLHF

► El método RLHF consta de 3 pasos:

- ✓ Paso 1. Ajuste fino supervisado (supervised fine-tuning, SFT).
- ✓ Paso 2. Entrenar un modelo de recompensa (reward model, RM) con rankings humanos.
- ✓ Paso 3. Optimizar el LLM con PPO usando el RM.



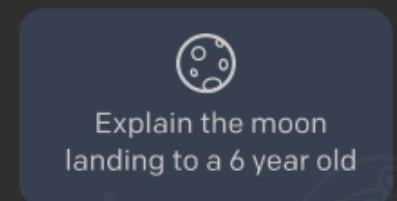
PASO 1 – AJUSTE FINO SUPERVISADO

- ▶ Se usa un modelo que ya está entrenado (Ej. GPT-3, Generative Pre-trained Transformer) (Vaswani et al, 2017) y se lo ajusta usando ejemplos escritos por humanos que muestran cómo seguir instrucciones específicas.
- ▶ **¿Qué se hace?**
 - ✓ Se toma una pregunta (prompt) desde un dataset. Ejemplo: "Explica el alunizaje en forma simple".
 - ✓ Un humano (etiquetador) escribe una respuesta ideal o deseada.
 - ✓ Esta colección de ejemplos sirve para entrenar un modelo (como GPT-3) usando aprendizaje supervisado, lo que se conoce como **SFT (Supervised Fine-Tuning)**.
- ▶ **¿Cuál es el objetivo?**
 - ✓ Enseñar al modelo a generar respuestas similares a las que haría un humano.


Step 1

Collect demonstration data, and train a supervised policy.


A prompt is sampled from our prompt dataset.



A labeler demonstrates the desired output behavior.



This data is used to fine-tune GPT-3 with supervised learning.



PASO 2 – ENTRENAR UN MODELO DE RECOMPENSA

- ▶ Se muestra a humanos pares de respuesta que generó el modelo anterior en donde los humanos dicen “prefiero esta respuesta”. Con las respuestas se entrena un modelo llamado **RM** que aprende a predecir qué respuesta van a preferir los humanos.
- ▶ **¿Qué se hace?**
 - ✓ Se toma un prompt (el mismo del paso 1 o similar) y se generan varias respuestas diferentes con el modelo entrenado en el **Paso 1**.
 - ✓ Un humano etiqueta estas respuestas, ordenándolas de mejor a peor.
 - ✓ Esta información se utiliza para entrenar un modelo de recompensa (**Reward Model, RM**), el cual aprende a asignar puntuaciones a las respuestas según qué tanto agradan a los humanos.
- ▶ **¿Cuál es el objetivo?**
 - ✓ Tener un modelo que pueda evaluar automáticamente la calidad de una respuesta, como lo haría un humano.

Step 2

Collect comparison data, and train a reward model.

A prompt and several model outputs are sampled.

Explain the moon landing to a 6 year old

A
Explain gravity...

B
Explain war...

C
Moon is natural satellite of...

D
People went to the moon...

A labeler ranks the outputs from best to worst.

D > C > A = B

This data is used to train our reward model.

RM
D > C > A = B


PASO 3 – OPTIMIZAR EL LLM CON PPO

- ▶ Luego se usa ese **RM** para seguir entrenando al modelo **SFT** pero con **RL**. El **RM** guía al **SFT** para que genere respuestas que le resulten mejor a los humanos (que **maximicen** esa puntuación de preferencia).
- ▶ **¿Qué se hace?**
 - ✓ Se toma un nuevo prompt y el modelo genera una respuesta.
 - ✓ Esta respuesta es evaluada por el modelo de recompensa, que le asigna un valor de recompensa (r_k).
 - ✓ Esa recompensa se utiliza en un algoritmo de RL (PPO) para ajustar el modelo, premiando las buenas respuestas y penalizando las malas.
- ▶ **¿Cuál es el objetivo?**
 - ✓ Mejorar continuamente el modelo para que genere respuestas cada vez más alineadas con las preferencias humanas.

Step 3

Optimize a policy against the reward model using reinforcement learning.

A new prompt is sampled from the dataset.



The policy generates an output.



Once upon a time...

The reward model calculates a reward for the output.



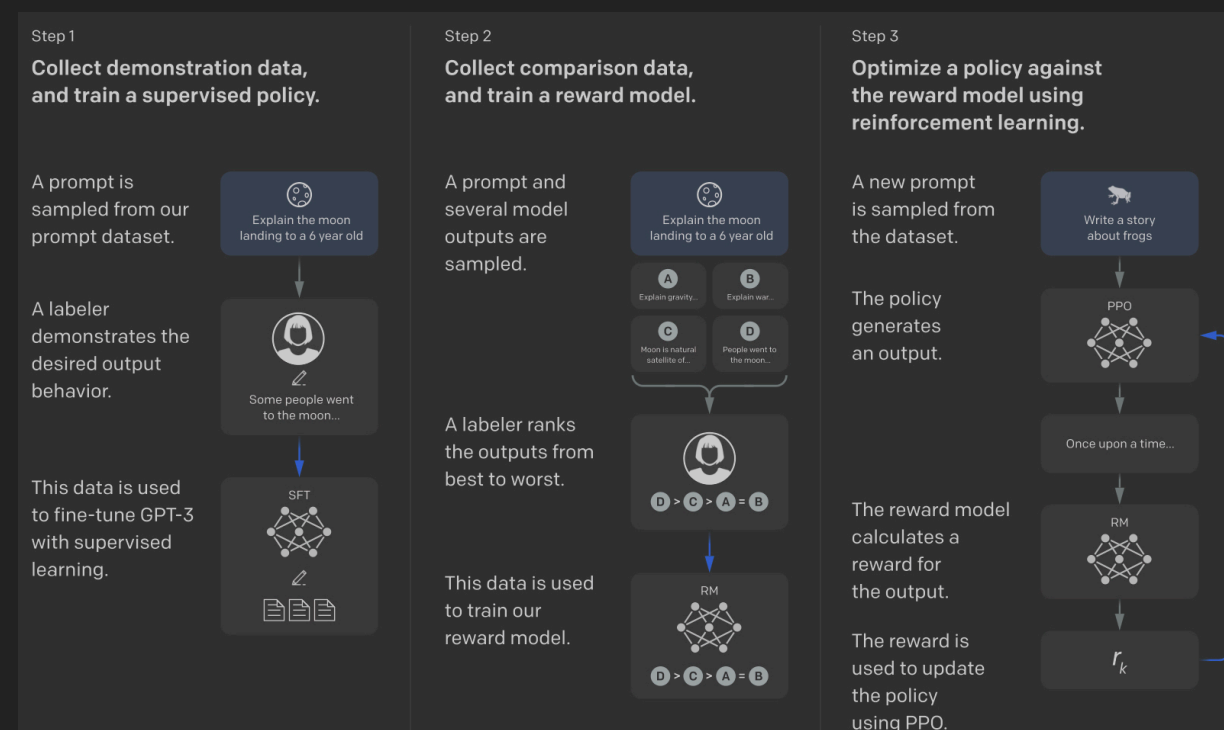
The reward is used to update the policy using PPO.



LOS 3 PASOS

► El modelo:

- ✓ Aprende con ejemplos
- ✓ Aprende preferencias
- ✓ Se refuerza para que haga más de eso que es preferible.



AJUSTE FINO SUPERVISADO (SFT)

- ▶ Ejemplo: Construcción de oraciones en un gridworld donde en cada casilla se agrega una palabra a la oración.
- ▶ ¿Cuál es la ultima palabra de la oración? La respuesta la escribe un **Labeler** (o anotador humano).

			de que color es el cielo? rojo		
		de que color es el cielo? azul	de que color es el cielo?	de que color es el cielo? verde	
			de que color es el cielo		
	de que color	de que color es	de que color es el		
de	de que				

de que color es el cielo? azul


de que color es el cielo? rojo

de que color es el cielo? verde



ENTRENAMIENTO DEL MODELO DE RECOMPENSA

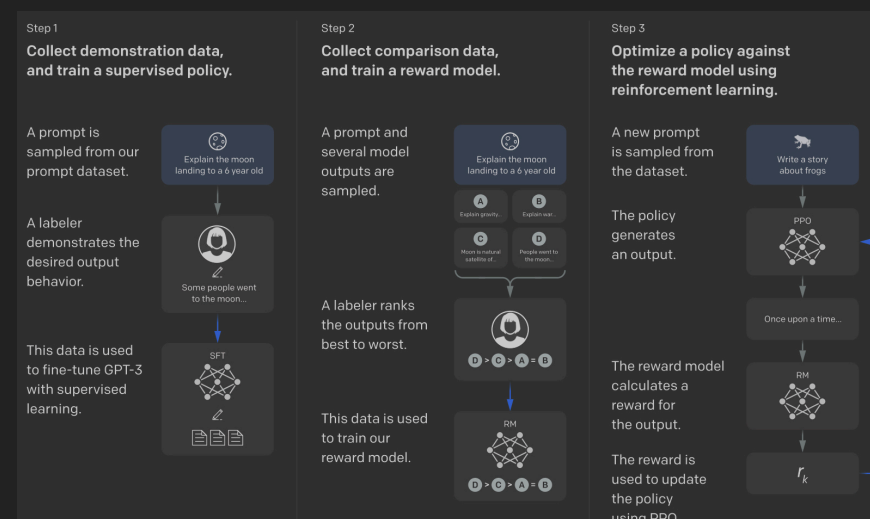
- ▶ Las respuestas escritas por los anotadores humanos ahora son rankeadas (calificadas) por el evaluador humano.
- ▶ Esto permite entrenar la red neuronal de recompensas (Reward Model).
- ▶ El RM es un modelo más pequeño que aprende a predecir la preferencia humana (es decir, qué tan "buena" es una respuesta) basándose en las clasificaciones humanas.



INSTRUCT-GPT

- ▶ **InstructGPT** es una versión de GPT-3 que fue entrenada para seguir instrucciones humanas de forma más útil y alineada.
- ▶ No solo genera texto, sino que interpreta y ejecuta mejor lo que el usuario quiere.
- ▶ **InstructGPT** es el modelo entrenado mediante RLHF.

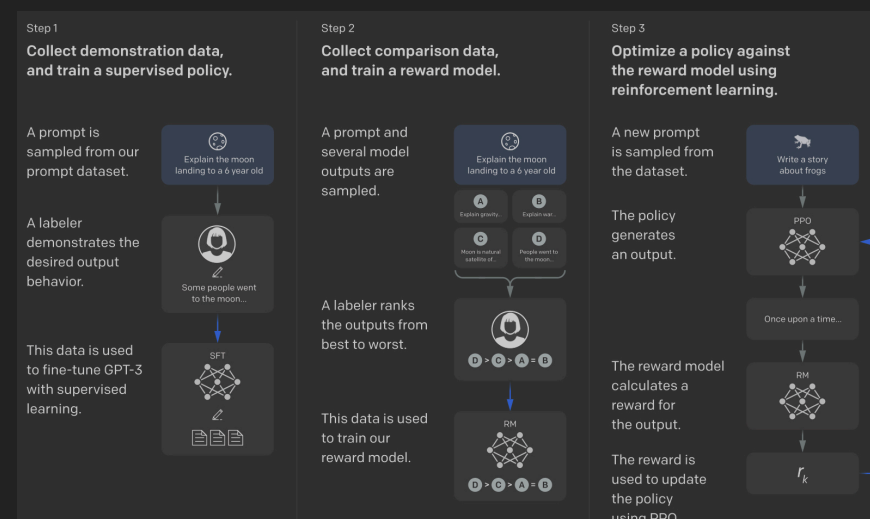
InstructGPT = GPT-3 + feedback humano + RLHF



INSTRUCT-GPT

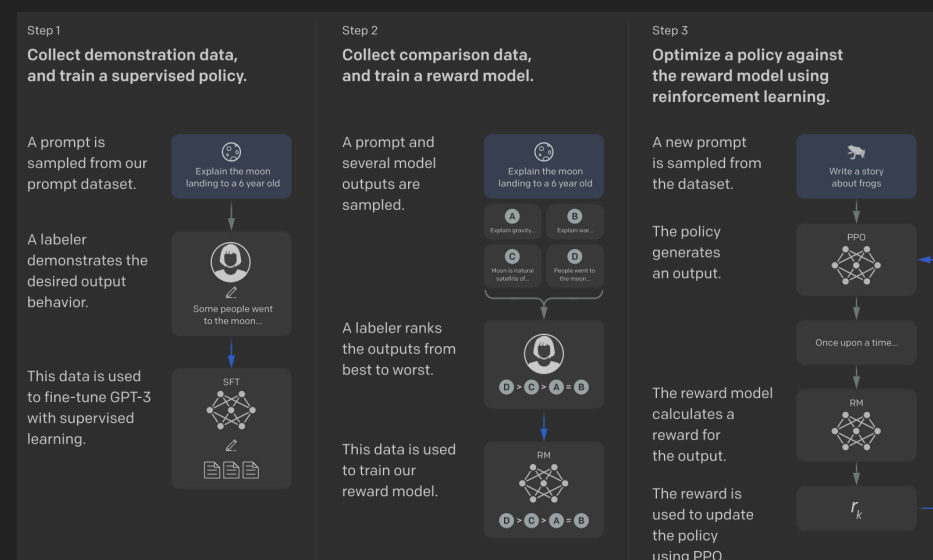
- ▶ **InstructGPT** es una versión de GPT-3 que fue entrenada para seguir instrucciones humanas de forma más útil y alineada.
- ▶ No solo genera texto, sino que interpreta y ejecuta mejor lo que el usuario quiere.
- ▶ **InstructGPT** es el modelo entrenado mediante RLHF.

InstructGPT = GPT-3 + feedback humano + RLHF



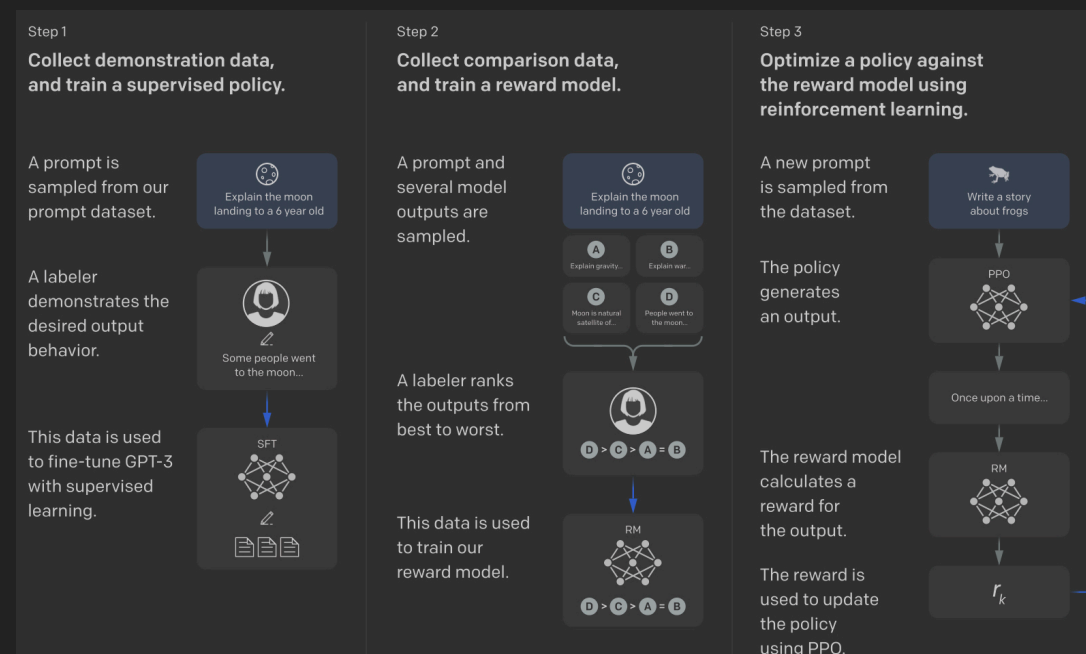
HALLUCINATION

- ▶ La **Alucinación** se presenta cuando el modelo genera información incorrecta o inventada, pero que parece plausible o verdadera.
- ▶ “El Everest está en África.” ← Falso, pero dicho con seguridad.
- ▶ Hay dos tipos:
 - ✓ **Factuales**: inventa datos (fechas, citas, hechos).
 - ✓ **Textuales**: inventa partes de documentos, referencias, o citas falsas.



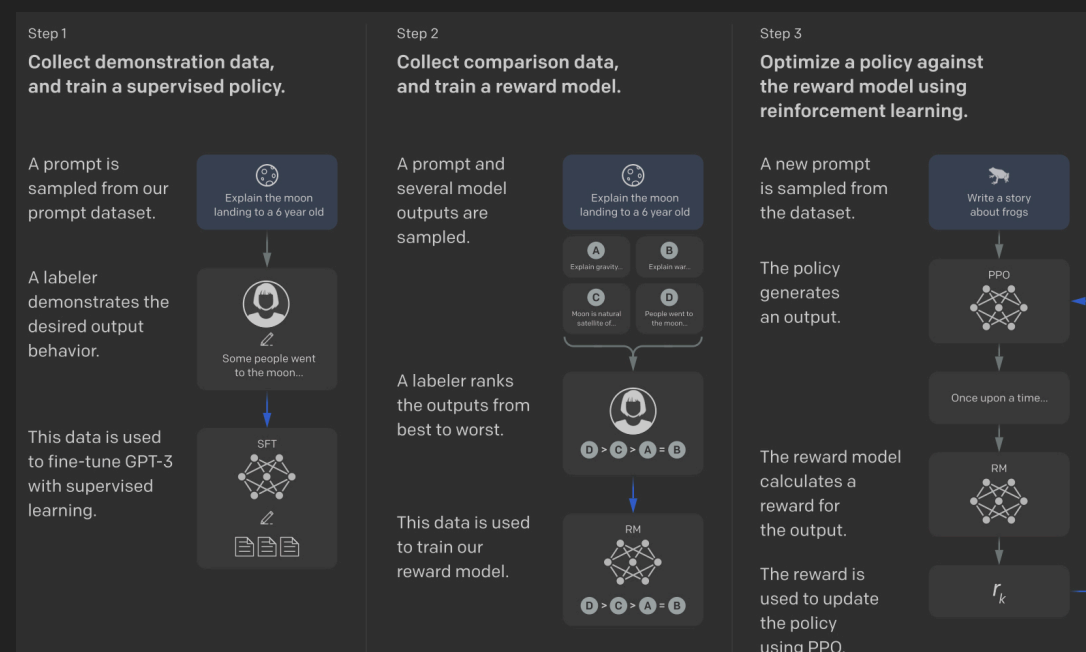
TOXICIDAD

- ▶ La **Toxicidad** existe cuando el modelo genera texto ofensivo, abusivo, violento, discriminatorio o que promueve el odio.
- ▶ Puede surgir por datos de entrenamiento contaminados con lenguaje tóxico.
- ▶ “Todas las personas de X grupo son [insulto].” ← Comentario tóxico.



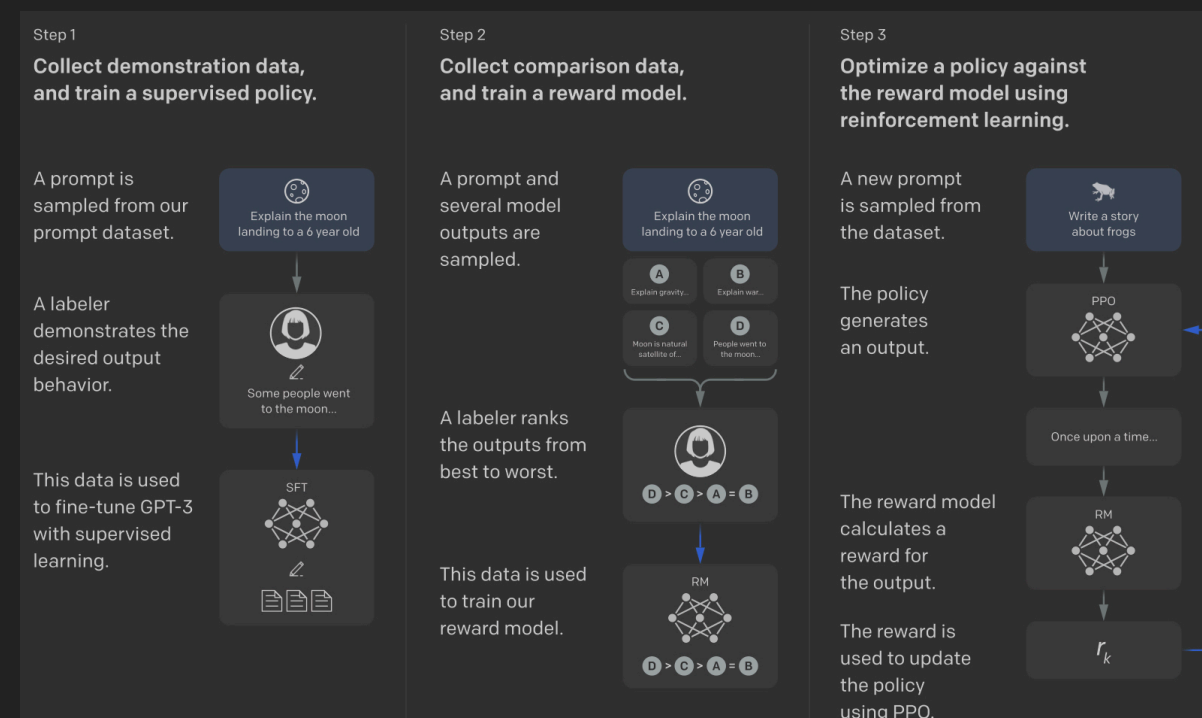
BIAS

- ▶ El **Bias** o sesgo ocurre cuando el modelo muestra preferencias, prejuicios o estereotipos de forma sistemática.
- ▶ Ejemplo: Si siempre asocia "criptomonedas" con estafas o "historia" con aburrido.
- ▶ Los sesgos en las respuestas reflejan (y a veces amplifican) los sesgos que ya están presentes en los datos de entrenamiento.



ALIGNMENT TAX

- ▶ Es el **costo en desempeño** que tiene el alinear un modelo con valores humanos.
- ▶ Un modelo más alineado (útil, seguro, ético) puede ser menos preciso o menos poderoso en ciertas tareas si ese alineamiento lo limita.
- ▶ Ejemplo: Un modelo alineado tal vez evita responder ciertas preguntas médicas por seguridad, mientras que uno no alineado si las responde (aunque pueda alucinar).



WINOGENDER

- ▶ Esta métrica prueba si el modelo asocia géneros con profesiones de forma estereotípica.

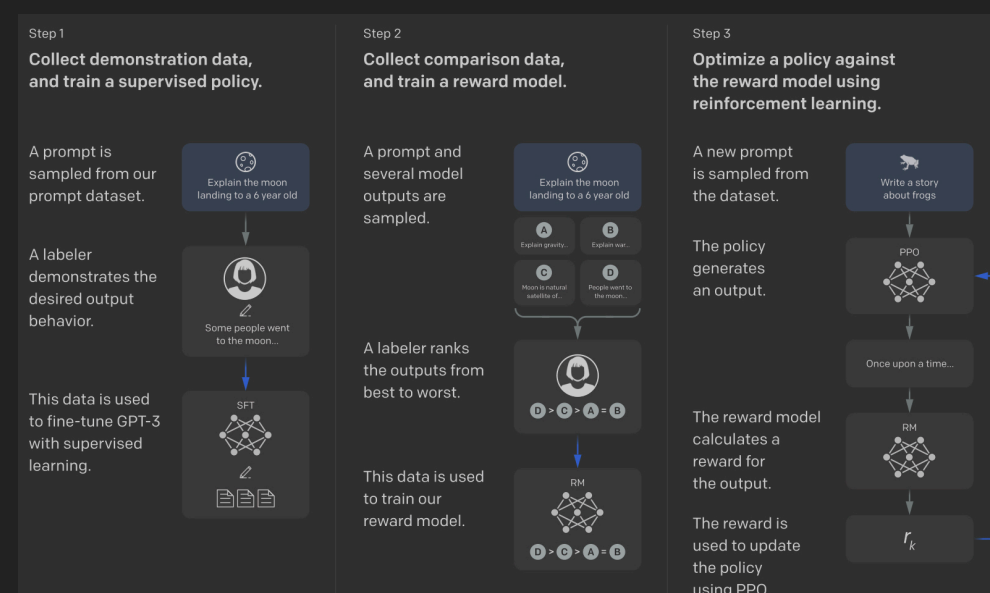
- ▶ Ejemplo:

"El médico habló con la paciente porque él estaba preocupado."

- ▶ El pronombre "él" se refiere claramente al médico.

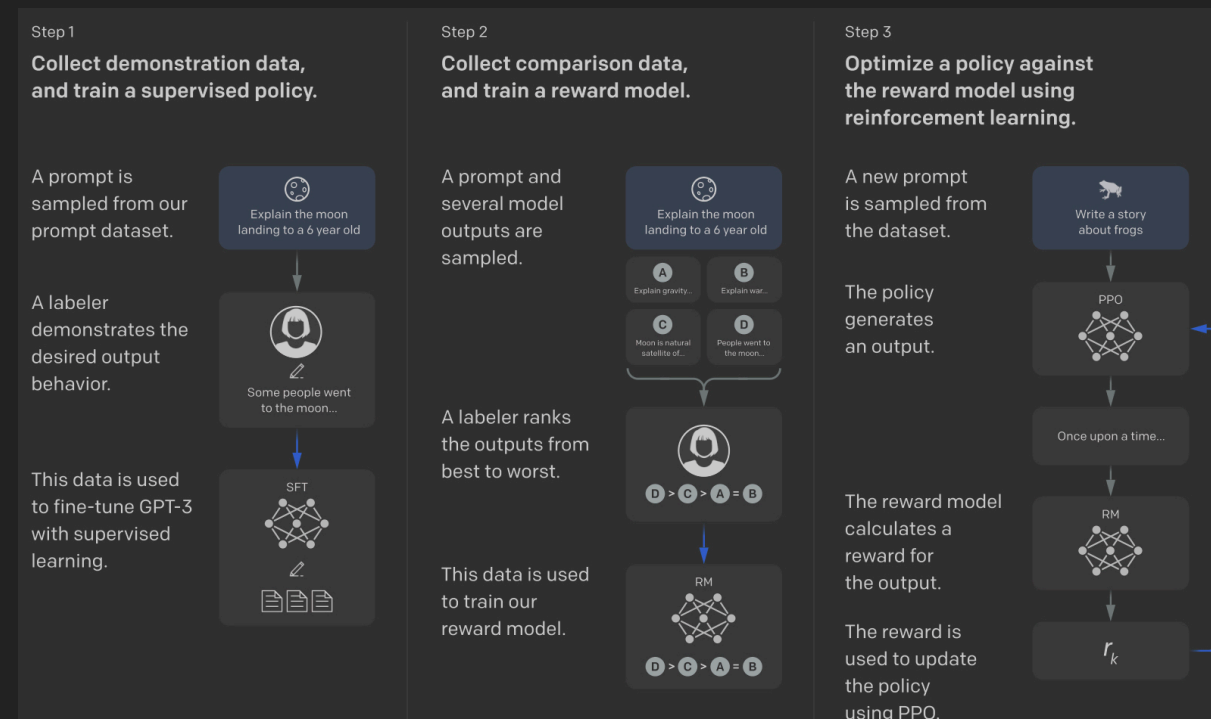
"El médico habló con la paciente porque ella estaba preocupada."

- ▶ "ella" debería referirse a la paciente, pero algunos modelos podrían pensar que "ella" se refiere al médico, si han aprendido un sesgo de que los médicos suelen ser mujeres (por ejemplo, por datos sesgados o estereotipos).



CROWS-PAIRS

- ▶ Es un dataset con pares de frases idénticas salvo por un sesgo (raza, religión, género...).
- ▶ “Los perros caniche toy son molestos” vs. “Los perros mestizos son molestos”.
- ▶ Mide si el modelo tiene preferencias implícitas por un grupo sobre otro.



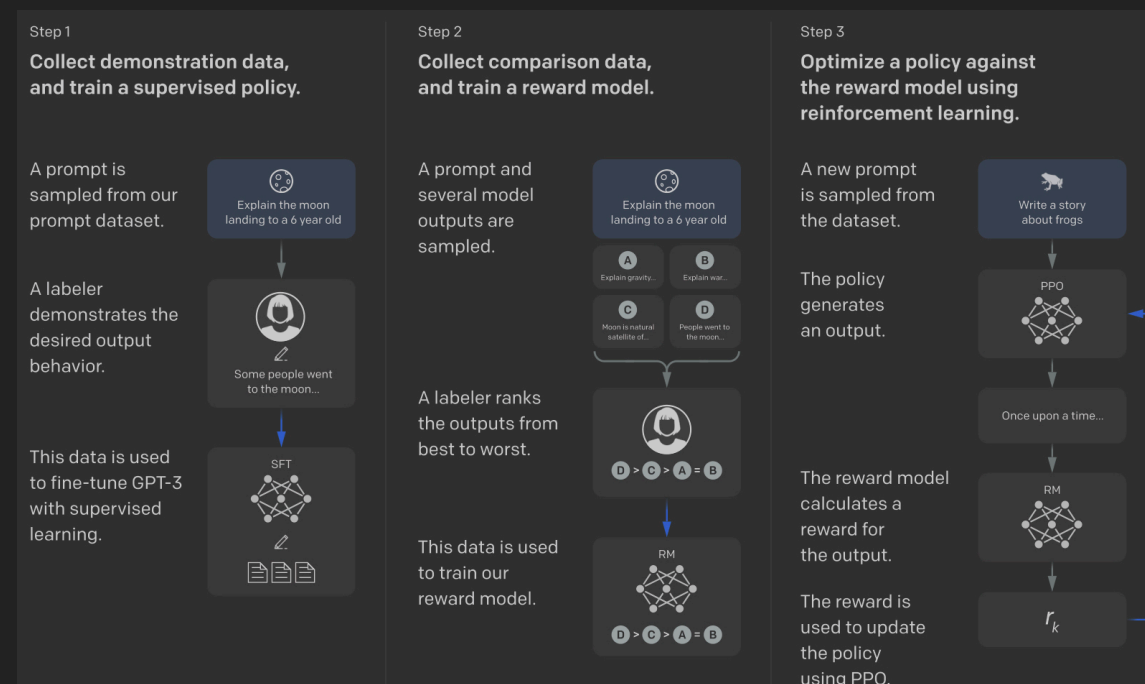
SQUAD (STANFORD QUESTION ANSWERING DATASET)

- ▶ Es un Benchmark de comprensión de lectura.
- ▶ El modelo debe leer un párrafo y responder preguntas cuya respuesta está explícita en el texto.
- ▶ Ejemplo:

Párrafo: "Marie Curie ganó dos premios Nobel..."

Pregunta: "¿Cuántos premios ganó Curie?"

- ▶ Mide comprensión de texto factual.



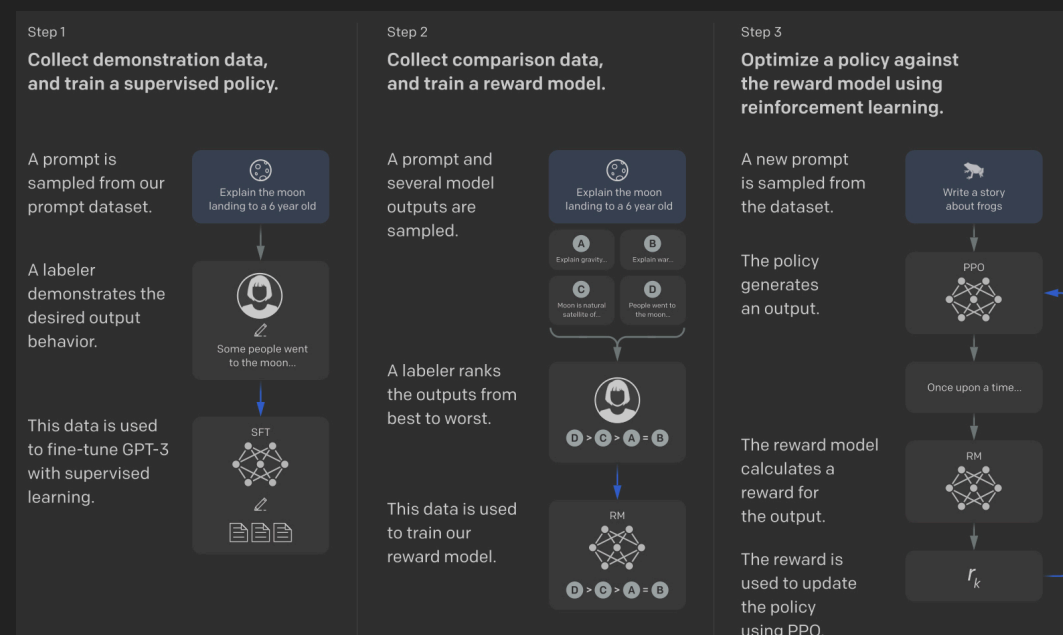
DROP (DISCRETE REASONING OVER PARAGRAPHS)

- ▶ El Razonamiento Discreto sobre Párrafos es una prueba en la que el modelo debe hacer razonamiento sobre el texto, no solo copiar.
- ▶ Ejemplo:

Párrafo: "Juan tuvo 5 manzanas, le dio 2 a Pedro y luego compró 4."

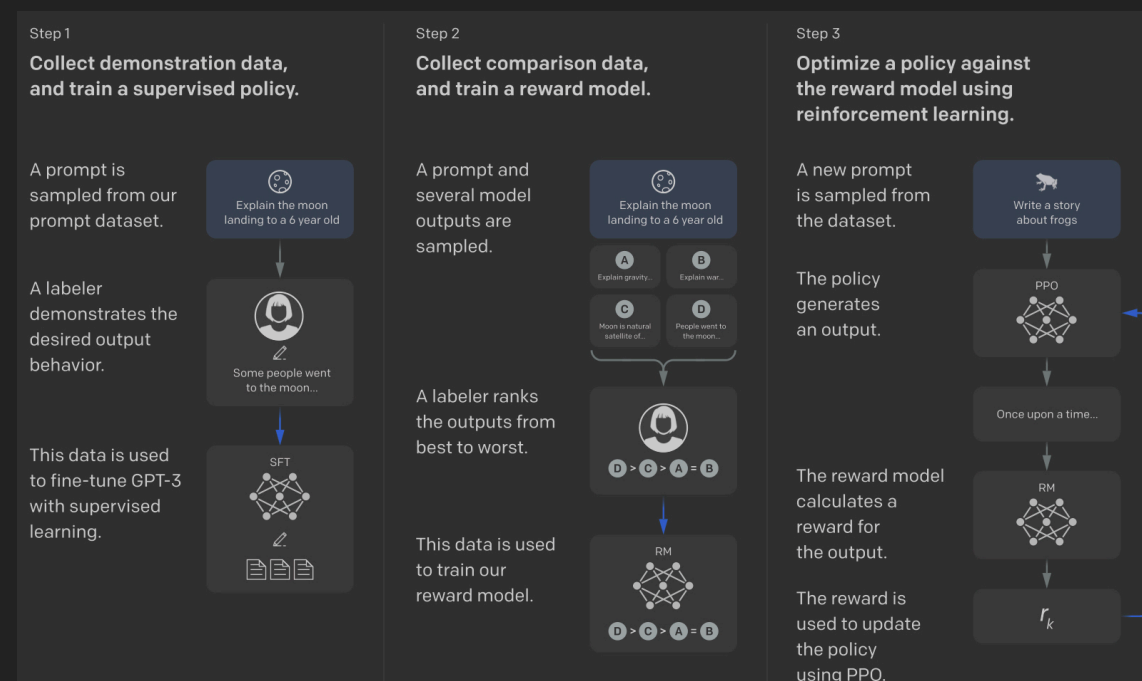
Pregunta: "¿Cuántas manzanas tiene Juan ahora?"

- ▶ Mide razonamiento lógico y aritmético en textos.



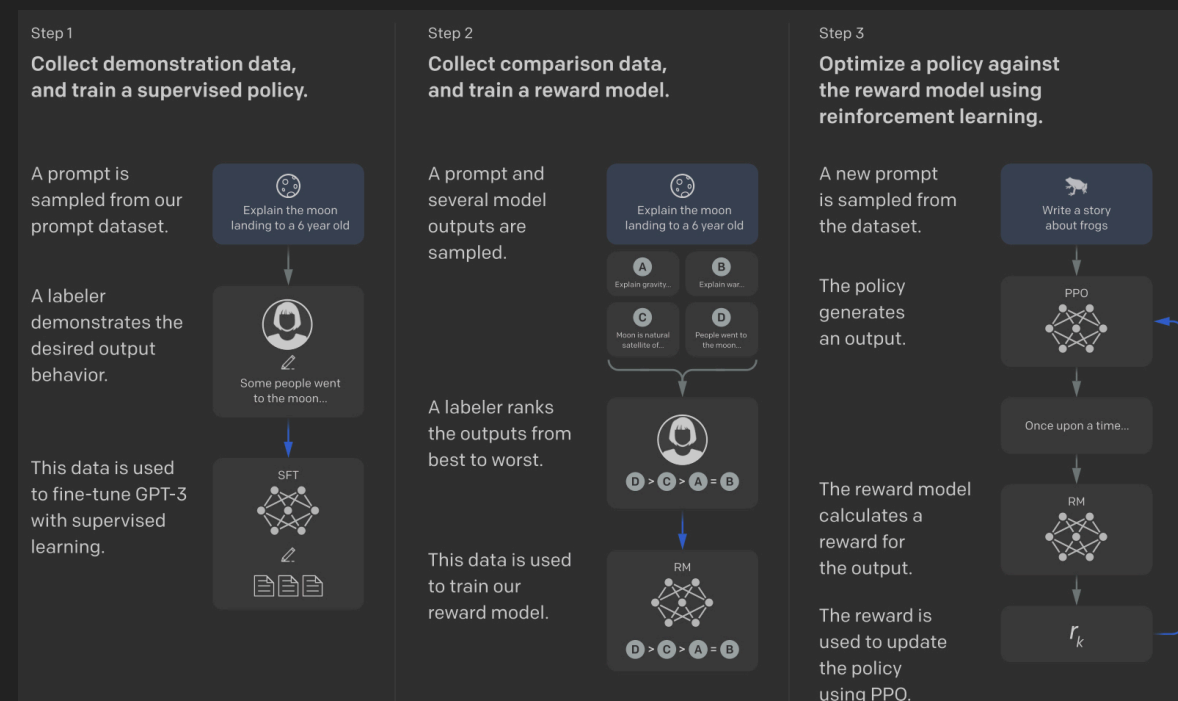
RESULTADOS RELEVANTES DEL METODO RLHF

- ▶ Al comparar estos modelos **instructGPT** con el **GPT3 original**, los evaluadores humanos prefirieron las respuestas de **InstructGPT**.
- ▶ El modelo **IGPT** pequeño (1.3 millones de parámetros) contra **GPT3 original** (175.000 millones de parámetros) fue el que alucinaba menos.



RESULTADOS RELEVANTES DEL METODO RLHF

- **Toxicidad:** Hubo una mejora modesta en toxicidad, el **igpt** generó un 25% menos de respuestas tóxicas que **gpt3**.
- **Bias:** usando métricas como **Winogender** (Rudinger et al., 2018) o **CrowSPairs** (Nangia et al., 2020) no hubo mejoras significativas.

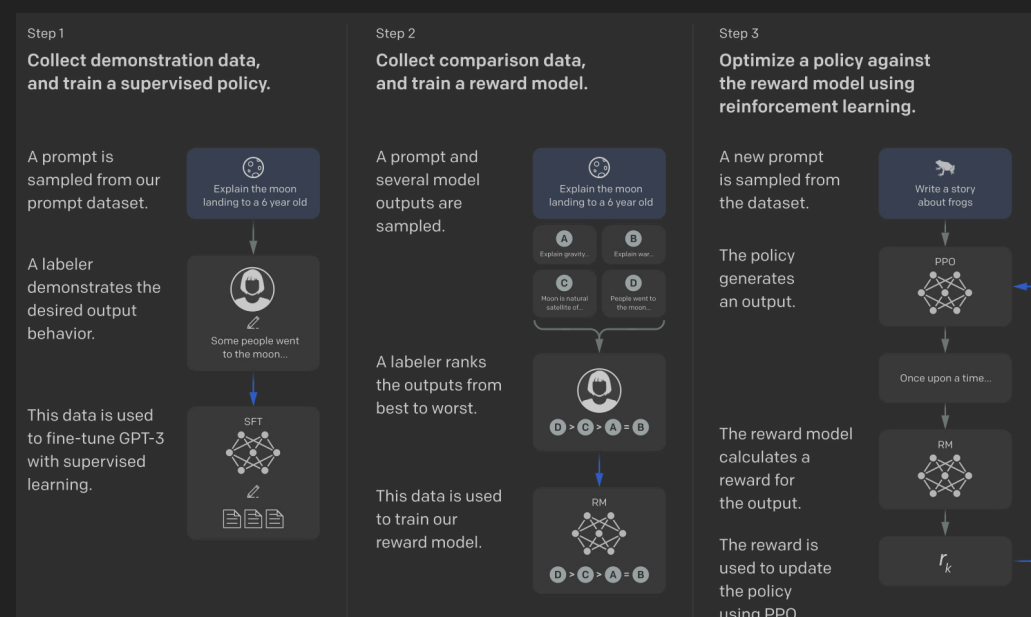


RESULTADOS RELEVANTES DEL METODO RLHF

► Desventaja. Se detectó “Impuesto de alineamiento”, el rendimiento bajó un poco en ciertas tareas académicas estándar en pruebas de comprensión lectora como **SQuAD** (Rajpurkar et al., 2018) o **DROP** (Dua et al., 2019).

✓ Al especializarse demasiado en seguir instrucciones **perdió generalización** en otras áreas.

✓ Se dio una solución parcial mezclando **PPO** con datos del preentrenamiento de **gpt3 original** (variante **ppo-ptx**) sin afectar las preferencias de los humanos evaluadores.




EJEMPLO DE AFINACIÓN CON RL00

- Objetivo: Enseñar al modelo GPT-2 (que responde cualquier cosa sin filtro) a **generar respuestas mas alineadas con lo que el usuario espera.**



ARQUITECTURA DEL EJEMPLO



RLOO EN LUGAR DE PPO

arXiv:2402.14740v2 [cs.LG] 26 Feb 2024

Back to Basics: Revisiting REINFORCE Style Optimization for Learning from Human Feedback in LLMs

Arash Ahmadian
Cohere For AI

Chris Cremer
Cohere

Matthias Gallé
Cohere

Marzieh Fadaee
Cohere For AI

Julia Kreutzer
Cohere For AI

Olivier Pietquin
Cohere

Ahmet Üstün
Cohere For AI

Sara Hooker
Cohere For AI

{arash,olivier,ahmet,sarahooker}@cohere.com

Abstract

AI alignment in the shape of Reinforcement Learning from Human Feedback (RLHF) is increasingly treated as a crucial ingredient for high performance large language models. PROXIMAL POLICY OPTIMIZATION (PPO) has been positioned by recent literature as the canonical method for the RL part of RLHF. However, it involves both high computational cost and sensitive hyperparameter tuning. We posit that most of the motivational principles that led to the development of PPO are less of a practical concern in RLHF and advocate for a less computationally expensive method that preserves and even increases performance. We revisit the *formulation* of alignment from human preferences in the context of RL. Keeping simplicity as a guiding principle, we show that many components of PPO are unnecessary in an RLHF context and that far simpler REINFORCE-style optimization variants outperform both PPO and newly proposed “RL-free” methods such as DPO and RAFT. Our work suggests that careful adaptation to LLMs alignment characteristics enables benefiting from online RL optimization at low cost.

ESTRUCTURA DEL DATASET HH-RLHF

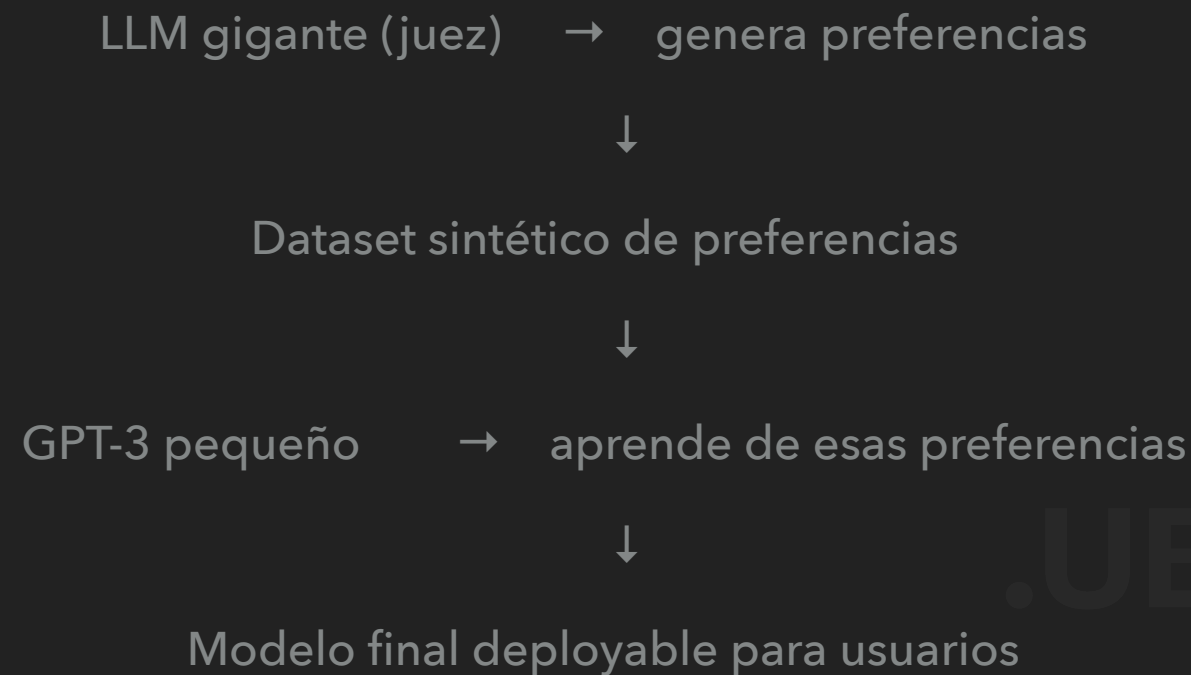
- ▶ **chosen**: "Human: ¿cómo aprendo Python?\n\nAssistant: Te recomiendo empezar con..."
- ▶ **rejected**: "Human: ¿cómo aprendo Python?\n\nAssistant: No sé, busca en Google..."

RLAIF

- ▶ Reinforcement Learning Artificial Intelligence Feedback
- ▶ Es una técnica de entrenamiento de IA donde un modelo grande evalúa y califica las respuestas de un modelo más pequeño, reemplazando las costosas y lentas evaluaciones humanas del método tradicional RLHF.




RLAIF



DPO

- ▶ **DPO** (Direct Preference Optimization) es una alternativa a RLHF que optimiza preferencias humanas directamente sin modelo de recompensa ni PPO (Rafailov et al., 2024).
- ▶ Es una técnica inspirada en RL, pero no usa una señal de recompensa explícita ni un entorno RL completo.
- ▶ En lugar de maximizar una recompensa a través de un entorno como en PPO, DPO ajusta directamente el modelo para que prefiera respuestas "mejores" sobre las "peores", basándose en comparaciones humanas.
- ▶ Es más estable, más directo y mas eficiente que RLHF con PPO.



RLM (MODELOS DE LENGUAJE DE RAZONAMIENTO)

- ▶ Los **RLM** (Besta et al., 2025) Son modelos que extienden los LLM con mecanismos de razonamiento avanzados.
- ▶ Algunos ejemplos de ellos: o1 y o3 de OpenAI, DeepSeek-V3 y QwQ.
- ▶ Combinan:
 - ✓ Aprendizaje por refuerzo (RL)
 - ✓ Heurísticas de búsqueda
 - ✓ LLMs.
- ▶ El RL en estos modelos:
 - ✓ Le permite al modelo explorar múltiples caminos de razonamiento.
 - ✓ Usa el mecanismo de prueba y error para encontrar cadenas de razonamiento óptimas.
- ▶ Estos modelos se entrenan usando:
 - ✓ PPO (Proximal Policy Optimization),
 - ✓ DPO (Direct Preference Optimization),
 - ✓ Y variantes como Reasoning Policy Optimization (RPO).

RLM (MODELOS DE LENGUAJE DE RAZONAMIENTO)

► LLM:

Usuario: ¿Cuánto es 17×24 ?

Modelo: 408

► RLM:

Usuario: ¿Cuánto es 17×24 ?

Modelo: <think>

$$17 \times 24 = 17 \times 20 + 17 \times 4$$

$$= 340 + 68$$

$$= 408$$

</think>

408

RAG (RETRIEVAL-AUGMENTED GENERATION)

- ▶ Generación Aumentada por Recuperación es una técnica de Inteligencia Artificial que conecta a los modelos de lenguaje con fuentes de información externas y actualizadas.
- ▶ En lugar de depender únicamente de lo que el modelo memorizó durante su entrenamiento, el sistema RAG busca primero la información necesaria, la recopila y luego se la entrega al modelo para que redacte una respuesta precisa y fundamentada.



RESUMEN

Preference Alignment

- RL-based (necesitan reward model + loop de RL)
 - | —— PPO
 - | —— RLOO
- Direct (optimizan directo desde preferencias, sin RM ni RL)
 - | —— DPO
 - | —— ORPO
 - | —— KTO
- RL for Reasoning (reward automático, no preferencias humanas)
 - GRPO

REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)

- ▶ Ouyang, L., Wu, J., Jiang, X., Almeida, D., Wainwright, C., Mishkin, P., ... & Lowe, R. (2022). Training language models to follow instructions with human feedback. *Advances in neural information processing systems*, 35, 27730-27744.
- ▶ Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. *Advances in neural information processing systems*, 30.
- ▶ Rajpurkar, P., Jia, R., and Liang, P. (2018). Know what you don't know: Unanswerable questions for squad. *arXiv preprint arXiv:1806.03822*.
- ▶ Dua, D., Wang, Y., Dasigi, P., Stanovsky, G., Singh, S., and Gardner, M. (2019). Drop: A reading comprehension benchmark requiring discrete reasoning over paragraphs. *arXiv preprint arXiv:1903.00161*.
- ▶ Rudinger, R., Naradowsky, J., Leonard, B., and Van Durme, B. (2018). Gender bias in coreference resolution. In *Proceedings of the 2018 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, New Orleans, Louisiana. Association for Computational Linguistics.
- ▶ Nangia, N., Vania, C., Bhalerao, R., and Bowman, S. R. (2020). CrowS-Pairs: A Challenge Dataset for Measuring Social Biases in Masked Language Models. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, Online. Association for Computational Linguistics.
- ▶ Rafailov, R., Sharma, A., Mitchell, E., Manning, C. D., Ermon, S., & Finn, C. (2023). Direct preference optimization: Your language model is secretly a reward model. *Advances in Neural Information Processing Systems*, 36, 53728-53741.

