

10

SOFT ACTOR-CRITIC

SOFT ACTOR-CRITIC (SAC)

- ▶ Fue presentado en 2018 con el título: "Soft Actor-Critic: Aprendizaje por refuerzo profundo de entropía máxima off-policy con un actor estocástico" (Haarnoja et al., 2018).
- ▶ Fue diseñado para ser eficiente, estable y adecuado para entornos continuos.
- ▶ SAC busca no solo maximizar la recompensa esperada, sino también maximizar la entropía de la política (fomenta políticas más exploratorias y robustas).




CONTRIBUCIONES

- ✓ Combina lo mejor de Actor-Critic y maximización de entropía (fomenta políticas estocásticas).
- ✓ Algoritmo Off-Policy: Usa un replay buffer para eficiencia en muestreo (como DQN, pero para políticas continuas).
- ✓ Estabilidad y rendimiento mejor que DDPG, PPO y TD3 en entornos continuos (biblioteca: MuJoCo, aplicación: Robótica).



ANALOGÍA

► Chef innovador.



CARACTERÍSTICAS DE SAC

- ▶ Maximizar la recompensa + maximizar la entropía de las acciones.
- ▶ La entropía mide que tan aleatoria o impredecible es la política => mayor exploración => menos probabilidad de atasco.
- ▶ Es off-policy, esto es, utiliza un buffer de repetición => aprende de los datos antiguos.
- ▶ Evita la inestabilidad de DDPG:
 - ✓ Usa un actor estocástico (probabilidad de que acción tomar).
 - ✓ El mismo objetivo de maximizar la entropía funciona como un suavizador del aprendizaje (evita cambios bruscos).
 - ✓ Usa dos funciones Q para evitar sobrestimar los valores por ser optimista (dos críticos, similar a TD3).
- ▶ Se hicieron pruebas quitando partes (estudios de ablación).
- ▶ SAC es sensible a los hiperparámetros => temperatura (ajusta cuánta importancia le otorga a la entropía).

PSEUDOCÓDIGO Y ARQUITECTURA DE SAC

Algorithm 1 Soft Actor-Critic

Initialize parameter vectors $\psi, \bar{\psi}, \theta, \phi$.

for each iteration **do**

for each environment step **do**

 1 $\mathbf{a}_t \sim \pi_\phi(\mathbf{a}_t | \mathbf{s}_t)$

 2 $\mathbf{s}_{t+1} \sim p(\mathbf{s}_{t+1} | \mathbf{s}_t, \mathbf{a}_t)$

 3 $\mathcal{D} \leftarrow \mathcal{D} \cup \{(\mathbf{s}_t, \mathbf{a}_t, r(\mathbf{s}_t, \mathbf{a}_t), \mathbf{s}_{t+1})\}$

end for

for each gradient step **do**

 4 $\psi \leftarrow \psi - \lambda_V \hat{\nabla}_\psi J_V(\psi)$


 5 $\theta_i \leftarrow \theta_i - \lambda_Q \hat{\nabla}_{\theta_i} J_Q(\theta_i)$ for $i \in \{1, 2\}$

 6 $\phi \leftarrow \phi - \lambda_\pi \hat{\nabla}_\phi J_\pi(\phi)$


 7 $\bar{\psi} \leftarrow \tau\psi + (1 - \tau)\bar{\psi}$

end for


end for




ENSAYOS CON SAC




(a) Hopper-v1




(b) Walker2d-v1




(c) HalfCheetah-v1



(d) Ant-v1




(e) Humanoid-v1



(f) Humanoid (rllab)

EJEMPLO

- ▶ Aprendizaje del alunizaje con LunarLanderContinuous de Gymnasium y con la biblioteca de agentes Stable Baseline 3.



SB3

- ▶ **learning_starts**. Número de pasos de interacción con el entorno antes de comenzar el aprendizaje. Ayuda a llenar el buffer con experiencias variadas antes de actualizar la red.
- ▶ **tau**. Parámetro de interpolación suave para la actualización de la red objetivo V' (target network):
 - ✓ $\text{target_param} = \text{tau} * \text{param} + (1 - \text{tau}) * \text{target_param}$
 - ✓ Un valor pequeño da actualizaciones más estables.
- ▶ **train_freq**. Frecuencia con la que se entrena el modelo (en pasos del entorno), 1 significa que se entrena después de cada paso.
- ▶ **gradient_steps**. Número de pasos de gradiente a realizar por cada llamada de entrenamiento. Generalmente igual a **train_freq** para un entrenamiento equilibrado.

```
model = SAC(  
    policy='MlpPolicy',  
    env=train_env,  
    learning_rate=3e-4,  
    buffer_size=1000000,  
    learning_starts=10000,  
    batch_size=256,  
    tau=0.005,  
    gamma=0.99,  
    train_freq=1,  
    gradient_steps=1,  
    verbose=1,  
    seed=42  
)
```

SB3 – EJEMPLO 1 (TRAIN_FREQ Y GRADIENT_STEP)

```
model = SAC("MlpPolicy", env, train_freq=4, gradient_steps=1, ...)
```

Paso de Entorno 1: Agente interactúa. Transición (s1, a1, r1, s2) se guarda en el replay buffer.

Paso de Entorno 2: Agente interactúa. Transición (s2, a2, r2, s3) se guarda.

Paso de Entorno 3: Agente interactúa. Transición (s3, a3, r3, s4) se guarda.

Paso de Entorno 4: Agente interactúa. Transición (s4, a4, r4, s5) se guarda.

train_freq alcanza el valor seteado , o sea 4 => se detiene la recolección de datos por un momento y se inicia la fase de entrenamiento:

Se extraerá un mini-batch del replay buffer.

Se realizará 1 paso de gradiente (porque gradient_steps=1).

Después de este paso de gradiente, el agente vuelve a interactuar con el entorno.

SB3 – EJEMPLO 2 (TRAIN_FREQ Y GRADIENT_STEP)

```
model = SAC("MlpPolicy", env, train_freq=4, gradient_steps=5, ...)
```

Paso de Entorno 1, 2, 3, 4: Agente interactúa, datos se guardan.

train_freq=4 alcanza el valor seteado. Se inicia la fase de entrenamiento:

Paso de Gradiente 1: Se extrae mini-batch A, se calculan pérdidas, se actualizan pesos.

Paso de Gradiente 2: Se extrae mini-batch B (diferente de A), se calculan pérdidas, se actualizan pesos.

Paso de Gradiente 3: Se extrae mini-batch C, se calculan pérdidas, se actualizan pesos.

Paso de Gradiente 4: Se extrae mini-batch D, se calculan pérdidas, se actualizan pesos.

Paso de Gradiente 5: Se extrae mini-batch E, se calculan pérdidas, se actualizan pesos.


gradient_steps=5, o sea, alcanza el valor seteado. Termina la fase de entrenamiento.

El agente vuelve a interactuar con el entorno.



SOFT ACTOR-CRITIC V2 (SAC-V2)

- ▶ Una nueva versión fue presentada en 2019 con el título: "Soft Actor-Critic: Algorithms and Applications" (Haarnoja et al., 2019).
- ▶ **Mejora:** Autoajuste de la temperatura de entropía (α).



VARIANTES DE SAC

- ▶ **TQC (Truncated Quantile Critics)** (Kuznetsov et al., 2020)
- ▶ Paper: Controlling Overestimation Bias with Truncated Mixture of Continuous Distributional Quantile Critics
- ▶ Problema:
 - ✓ En SAC aun existe sobreestimación.
- ▶ Solución:
 - ✓ Representar el valor Q como una distribución de cuantiles.
 - ✓ Tener varios críticos.
 - ✓ Antes de calcular el target, eliminar los cuantiles más optimistas.

VARIANTES DE SAC

- ▶ **CrossQ** (Bhatt et al., 2024)
- ▶ Paper: CrossQ: Batch Normalization in Deep Reinforcement Learning for Greater Sample Efficiency and Simplicity
- ▶ Problema:
 - ✓ Lentitud de las target network de SAC.
- ▶ Solución:
 - ✓ elimina las target networks.
 - ✓ agrega Batch Normalization (reescalamiento inserto dentro de una capa de la red neuronal).
 - ✓ iguala o supera a REDQ, DroQ y SAC en eficiencia de muestras.

REFERENCIAS BIBLIOGRÁFICAS Y WEB (I)

- ▶ Haarnoja, T., Zhou, A., Abbeel, P., & Levine, S. (2018, July). Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In International conference on machine learning (pp. 1861-1870). Pmlr.
- ▶ Haarnoja, T., Zhou, A., Hartikainen, K., Tucker, G., Ha, S., Tan, J., & Levine, S. (2019). Soft actor-critic algorithms and applications. arXiv preprint arXiv:1812.05905.
- ▶ Kuznetsov, A., Shvechikov, P., Grishin, A., & Vetrov, D. (2020). Controlling overestimation bias with truncated mixture of continuous distributional quantile critics. Proceedings of the 37th International Conference on Machine Learning (ICML), 5556-5566.
- ▶ Chen, X., Wang, C., Zhou, Z., & Ross, K. W. (2021). Randomized ensembled double Q-learning: Learning fast without a model. En International Conference on Learning Representations (ICLR 2021). arXiv. <https://arxiv.org/abs/2101.05982>.
- ▶ Hiraoka, T., Imagawa, T., Hashimoto, T., Onishi, T., & Tsuruoka, Y. (2022). Dropout Q-functions for doubly efficient reinforcement learning. En International Conference on Learning Representations (ICLR 2022). <https://openreview.net/forum?id=xCVJMsPv3RT>.
- ▶ Bhatt, A., Palenicek, D., Belousov, B., Argus, M., Amiranashvili, A., Brox, T., & Peters, J. (2024). CrossQ: Batch normalization in deep reinforcement learning for greater sample efficiency and simplicity. International Conference on Learning Representations (ICLR).